



AudiTim Dokumentation

Bearbeitungszeitraum

Gruppe, Kurs

Gruppenmitglieder

10 Wochen

5, INF2023AI

Aaron Reiber, Jan-David Oberländer,
Luca Müller, Moritz Flaig

Inhaltsverzeichnis

1	Einleitung	1
1.1	Projektüberblick	1
1.2	Ziele und Motivation	1
1.3	MVP und Qualitätsmerkmale	2
2	SFMEA-Analyse	3
3	Auswahl und Bewertung der Hard- und Softwarekomponenten	5
3.1	Hardwarekomponenten	5
3.2	Softwarekomponenten	7
4	Befestigung der Hardware	11
4.1	Platzungskonzept	11
4.2	Deckenhalterung	12
4.3	ESP32-Halterung	12
4.4	Sensor-Halterung	14
5	Algorithmus zur Schallquellenlokalisierung	15
5.1	Grundprinzipien	15
5.2	Betrachtete Verfahren	15
5.3	Vergleich der Verfahren	21
5.4	Fazit	21
6	API-Kommunikation	23
6.1	Datenmengen und Optimierungsansätze	23
	Literaturverzeichnis	i

1 Einleitung

Im Rahmen des Software-Engineering-Projekts wird in einem Team ein System zur akustischen Raumüberwachung entwickelt. Ziel des Projekts ist die kontinuierliche Erfassung und spätere Analyse der Lautstärkeverteilung in einem typischen Vorlesungsraum über den Zeitraum mehrerer Tage hinweg.

1.1 Projektüberblick

Die Umsetzung erfolgt nach agilen Prinzipien unter Anwendung von Scrum, wobei die jeweiligen Sprints von Freitag bis Freitag festgelegt wurden.

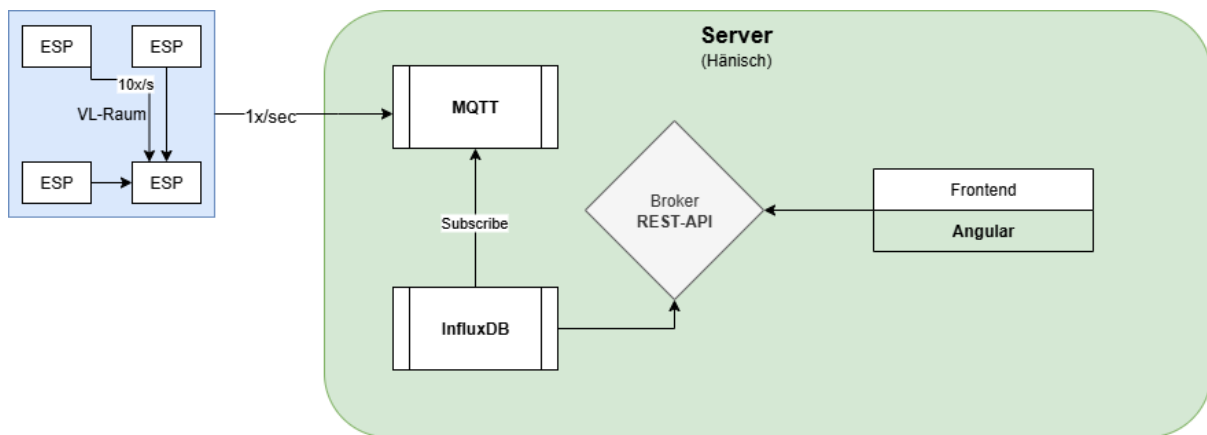
Die technische Architektur sieht den Einsatz von vier Mikrocontroller-Einheiten (ESP32) vor, die jeweils mit einem Mikrofon oder einem Dezibel-Messsensor ausgestattet werden. Die Geräte werden in den vier Ecken des Vorlesungsraums positioniert, um eine möglichst flächendeckende Abdeckung des Raumes zu gewährleisten. Über ein Kommunikationsprotokoll tauschen sich die ESPs untereinander aus und senden die gesammelten Messdaten gemeinsam an ein zentrales Backend.

1.2 Ziele und Motivation

Ziel ist es, ein skalierbares und robustes System zu entwickeln, das Lautstärkepegel über einen längeren Zeitraum erfassen kann. Die gesammelten Daten sollen im Backend gespeichert und im Nachgang analysiert werden. Hierbei sind verschiedene Darstellungsformen wie etwa Heatmaps oder zeitbasierte Diagramme denkbar, um Muster oder Auffälligkeiten im akustischen Verhalten des Raumes sichtbar zu machen.

1.3 MVP und Qualitätsmerkmale

Im Rahmen des MVPs soll ein verteiltes System zur akustischen Raumüberwachung auf Basis von vier Mikrocontrollern der ESP-Serie entwickelt werden. Jeder ESP wird über ein extern angeschlossenes Mikrofon verfügen, mit dem kontinuierlich Lautstärkedaten erfasst werden. Drei der Module sollen ihre Messwerte mithilfe des ESP-NOW-Protokolls an eine zentrale Einheit übermitteln, die zusätzlich eigene Daten erfasst. Die aggregierten Informationen aller vier Einheiten werden in festen Intervallen über das MQTT-Protokoll an einen Server gesendet und dort zeitsynchron in einer InfluxDB gespeichert. Über eine REST-API sollen die Daten einem Angular-basierten Web-Frontend zur Visualisierung der akustischen Messwerte zur Verfügung gestellt werden.



Auf Grundlage des MVPs sollen die folgenden Qualitätsmerkmale sichergestellt werden:

- **Echtheit & Qualität der Daten:** Nur qualitativ "gute" Daten z.B. durch optimierte Mikrofongehäuse ermöglichen realistische Messwerte und damit eine sinnvolle Analyse der akustischen Verhältnisse im Raum.
- **Accountability der Daten:** Es muss nachvollziehbar sein, welche Sensoren zu welchem Zeitpunkt welche Daten erfasst haben.

2 SFMEA-Analyse

Systemfunktion	Fehlermöglichkeit	Fehlerursache	Fehlerfolge	B	A	E	RPZ	Maßnahmen
Dezibel erfassen	Falsche oder keine Messwerte	Mikrofon defekt, Sensor ungeeignet	Ungenauere oder keine Daten	8	6	3	144	Robuste Mikros, Kalibrierung, Ersatzsensor bereit
ESP kommuniziert nicht mit anderen	Keine oder fehlerhafte Datenübertragung	WLAN-Probleme, falsches Protokoll	Daten gehen verloren, keine Heatmap	7	5	4	140	Netzwerk prüfen, Fallback, Fehler-Logs
Daten werden nicht ans Backend gesendet	ESP schickt keine Daten	Stromausfall, Code-crash, Timeout	Datenlücken, unvollständige Analyse	7	5	3	105	Watchdog, Logging, häufigere Syncs
GitHub-Zugang fehlerhaft	Kein Zugriff oder Merge-Konflikte	Rechte falsch, keine Git-Strategie	Team kann nicht arbeiten	6	4	2	48	Git-Workflow, Rechte regeln

Systemfunktion	Fehlermöglichkeit	Fehlerursache	Fehlerfolge	B	A	E	RPZ	Maßnahmen
Backend speichert keine Daten	Fehlerhafte Speicherung / Absturz	Server voll, Codefehler	Datenverlust, Ausfall	9	4	4	144	Monitoring, Logging, Backups, Testlauf
Daten werden falsch ausgewertet	Heatmap falsch / Werte inkonsistent	Algorithmusfehler, unvollständige Daten	Falsche Rückschlüsse	6	4	3	72	Testdaten prüfen, Algo validieren, Visualisierung testen
ESPs messen nicht synchron	Unterschiedliche Messzeitpunkte	Kein Sync, NTP fehlt	Daten nicht vergleichbar	7	5	4	140	NTP-Sync, Zeitstempel ergänzen



3 Auswahl und Bewertung der Hard- und Softwarekomponenten

3.1 Hardwarekomponenten

3.1.1 Mikrofonmodule

Zur Erfassung des Lautstärkepegels wurden drei unterschiedliche Mikrofonmodule in Betracht gezogen. Der erste Sensor ist ein kostengünstiges Modul "GY-MAX4466"(ca. 4 €), das ursprünglich als Klatschsensor konzipiert wurde. Der zweite Sensor ist das *Sound Level Meter V2.0* von DFRobot (ca. 40 €), das über zusätzliche Hardware zur Signalverarbeitung verfügt und den Schalldruckpegel bereits gefiltert und bereinigt im dBA-Format ausgibt. Der dritte in Betracht gezogene Sensor ist ein handelsübliches DB-Messgerät (ca. 20 €), das jedoch nicht für die Integration in das Projekt geeignet ist, da es keine digitale Schnittstelle bietet und somit nicht direkt mit dem ESP32 kommunizieren kann. Dieser Sensor wird daher zur Überprüfung der Ergebnisse verwendet, ist aber nicht für die direkte Integration in das Projekt vorgesehen.

Da die absolute Einheit (dBA) für die Auswertung im Rahmen eines 3D-Diagramms nicht zwingend erforderlich ist, wurde der Fokus auf die Vergleichbarkeit der analogen Ausgangssignale gelegt. Beide Sensoren wurden gleichzeitig an einem ESP32 betrieben und ihre Ausgangssignale mithilfe des *Serial Plotter* in Echtzeit visualisiert. Dabei zeigte sich, dass die Kurvenverläufe bei normalen Sprachgeräuschen nahezu identisch sind. Lediglich bei impulsartigen Geräuschen mit sehr geringer Distanz (z. B. Klatschen oder Klopfen) erzeugt das günstigere Mikrofon deutlich stärkere Peaks, während diese durch den DFRobot-Sensor wirksam herausgefiltert werden.



Hier sind die Sensorwerte des günstigeren Klatschensors (grün), sowie die des Teureren DbA sensors (gelb) dargestellt. Die In Blau dargestellte 5v Referenzlinie stellt den Maximalwert da, welcher von den Sensoren zurückgegeben werden kann.

Da die in den Vergleichsdiagrammen dargestellten Abweichungen bei größerem Abstand deutlich abnehmen und im Anwendungsfall als vernachlässigbar eingestuft werden können, wurde entschieden, den günstigeren Sensor zu verwenden. Um mögliche Reststörungen dennoch weiter zu reduzieren, ist geplant, eine mechanische Dämpfung oder Abschirmung am Sensor zu testen.

Insgesamt konnte festgestellt werden, dass der günstigere Sensor trotz fehlender dBA-Ausgabe für die angestrebte Visualisierung ausreichend präzise Ergebnisse liefert und somit für den weiteren Projektverlauf verwendet wird.

3.2 Softwarekomponenten

3.2.1 Entwicklungsumgebungen

Zu Beginn des Projekts wurden zwei gängige Entwicklungsumgebungen für die Programmierung von Mikrocontrollern evaluiert: die klassische *Arduino IDE*, welche auch von den betreuenden Dozierenden empfohlen wurde, sowie die moderne, zunehmend verbreitete *PlatformIO*-Erweiterung für Visual Studio Code.

Im Projektteam wird plattformübergreifend mit Linux, Windows 10 und Windows 11 gearbeitet. Beide Entwicklungsumgebungen sind grundsätzlich mit allen eingesetzten Betriebssystemen kompatibel. Zur Prüfung der technischen Umsetzbarkeit wurden zwei separate Repositories eingerichtet, in denen jeweils einfache Testprojekte zur Ansteuerung eines ESP32 implementiert wurden.

Beide IDEs konnten den Mikrocontroller erfolgreich ansprechen. PlatformIO bietet durch seine deklarative Verwaltung von Bibliotheken und Abhängigkeiten Vorteile in Bezug auf Reproduzierbarkeit und Build-Konsistenz. In der Praxis kam es jedoch auf einem System im Team zu anhaltenden technischen Problemen mit PlatformIO, die nicht zufriedenstellend gelöst werden konnten.

Um eine einheitliche und zuverlässige Entwicklungsgrundlage für alle Teammitglieder sicherzustellen, fiel die Entscheidung letztlich zugunsten der *Arduino IDE*. Diese ermöglicht eine barrierefreie Mitarbeit aller Beteiligten, auch wenn sie im Funktionsumfang nicht ganz an PlatformIO heranreicht.

3.2.2 Kommunikationsmethode

ESP-NOW wurde ausgewählt, da es im Vergleich zu anderen Protokollen einen deutlich geringeren Overhead besitzt und dadurch eine schnellere und effizientere Datenübertragung ermöglicht. Die Struktur ist weniger komplex, was die Implementierung vereinfacht und die Fehleranfälligkeit reduziert. Dadurch wird das System insgesamt robuster und zuverlässiger: ESP-Now ist ein Kommunikationsprotokoll von Espressif, das speziell für die ESP32- und ESP8266-Chips entwickelt wurde. Es verwendet die 2,4 Ghz Frequenz, welche eigentlich für WiFi Kommunikation verwendet wird. Im Gegensatz zu anderen Protokollen sind die Nachrichten auf Schicht 2 des ISO-OSI-Modells. Keine IP-Adressen sondern nur MAC-Adressen. Die ESPs müssen sich dafür im gleichen Kanal befinden. Die 2,4 Ghz Frequenz hat grundsätzlich nur 3 nutzbare Kanäle. Der zu verwendene Kanal muss von dem WLAN-Netz übernommen werden. Es ist mit relativ wenig Code möglich eine große Menge an Daten in sehr kurzen Zeitabschnitten zu senden. Theoretisch ist eine Datenübertragung von 1 bis 2 Mbps möglich. Die Nachrichtenlänge ist auf 250 Byte pro Paket beschränkt. Da unsere Nachrichten nur wenige Bit lang sind, haben wir hier keine Probleme. Das Protokoll hat keine festgelegten Sender/Empfänger Rollen. Jeder ESP kann senden und empfangen. In unserem Beispiel senden aber 3 ESPs und ein Edge-Device empfängt alle Daten. Es wird 10 mal pro Sekunde der Lautstärkepegel erfasst und gesendet.

3.2.3 ESP32

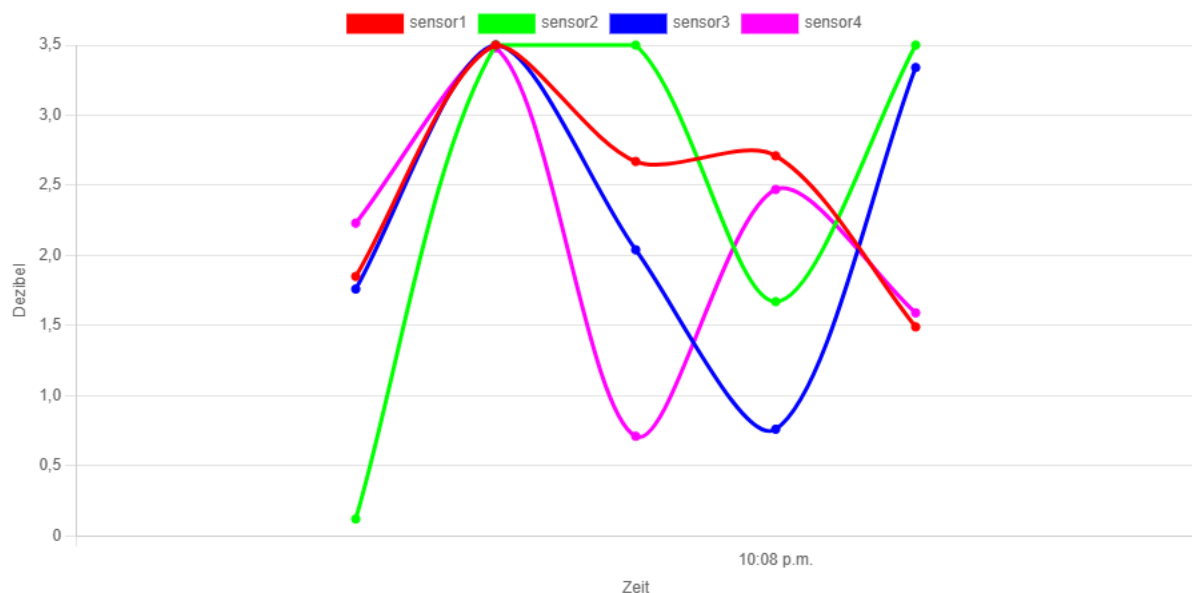
Die ESP-Module bieten im Vergleich zu klassischen Arduinos eine integrierte WLAN-Funktionalität und unterstützen direkt das ESP-NOW-Protokoll. Dadurch entfällt zusätzlicher Hardware- oder Softwareaufwand für die Netzwerkkommunikation. In Kombination mit ESP-NOW ergibt sich somit eine kompakte, performante und zuverlässige Lösung.

3.2.4 Frontend

Für die Umsetzung des Frontends wurde Angular gewählt, da im Team bereits umfangreiche Erfahrung mit diesem Framework vorhanden war. Angular bietet eine klare Struktur durch komponentenbasiertes Design, erleichtert die Wiederverwendbarkeit von UI-Elementen und unterstützt eine saubere Trennung von Logik und Darstellung. Dadurch konnte effizient und wartbar entwickelt werden.

Das Frontend läuft in einem eigenen Docker-Container und kommuniziert, über ein internes Netzwerk, mit dem separat laufenden Backend-Container. So bleibt die Architektur modular, skalierbar und einfach wartbar.

Die Darstellung der Daten wird über Angular-Komponenten realisiert, die Visualisierung in einfachen Liniendiagrammen wird mit der ng2-charts-Bibliothek ermöglicht.



3.2.5 Backend

Das Backend wurde mit Node.js und dem minimalistischen Framework Express.js umgesetzt. Express ist das am weitesten verbreitete Node.js-Framework für Webserver und APIs. Es bietet eine ausgereifte Middleware-Architektur, die sehr flexibel und modular ist. Im Vergleich zu ähnlich minimalistischen Frameworks wie Koa, das von den gleichen Entwicklern stammt, bietet Express mehr out-of-the-box Funktionalitäten

und eine größere Community mit umfangreichen Plugins und Support. (Community, 2025; Appventurez, 2025)

Koa hingegen ist moderner und basiert stärker auf ES6 Features wie `async/await`, was den Code oft sauberer macht. Allerdings ist Koa weniger „batteries included“ und erfordert mehr Initialaufwand und zusätzliche Libraries, um Funktionen bereitzustellen, die Express standardmäßig mitbringt. Für dieses Projekt, welches einen schnellen Einstieg, umfangreiche Dokumentation und stabile Middleware braucht, ist Express daher die pragmatischere Wahl. Zudem sind Gruppenmitglieder bereits mit Express vertraut, was die Einarbeitungszeit verkürzt und die Produktivität steigert.

Die Anbindung an eine InfluxDB erfolgt über die offizielle Client-Bibliothek. Die Entscheidung für InfluxDB basiert auf der Empfehlung der "Verteilten SystemeDozenten sowie der nahtlosen Integration in das Node.js-Backend, was die Implementierung vereinfacht. Neben dem Abrufen historischer Sensorwerte werden auch Funktionen zum Schreiben von Dummy-Daten bereitgestellt. Diese werden, solange die Verbindung zu den wirklichen Sensorwerten noch nicht hergestellt ist, zum Testen verwendet.

Das Backend ist ebenfalls in einem eigenen Docker-Container gekapselt. Die Kommunikation mit dem Frontend erfolgt über definierte HTTP-Endpunkte im Container-Netzwerk. Diese Trennung verbessert die Wartbarkeit und erlaubt eine flexible Skalierung beider Komponenten unabhängig voneinander.

4 Befestigung der Hardware


Um die Hardware des AudiTim-Systems sicher und stabil zu befestigen, sind verschiedene Montagemöglichkeiten verfügbar. Ein Großes Problem bei vorgefertigten Halterungen ist jedoch, dass diese oft an die Wand geschraubt oder anderweitig befestigt werden müssen. Daher fiel für unser Projekt die Wahl auf eine selbst designte Halterung, welche in einem 3D-Drucker hergestellt werden kann. Dies garantiert, dass keine Schäden an der Hardware oder am Raum, in welchem die Hardware montiert wird, entstehen.

4.1 Platzungskonzept

Aus akustischer Sicht liefern Messungen die zuverlässigsten Ergebnisse, wenn die Sensoren auf Kopfhöhe im Sitzen (1,2-1,5 m Höhe) angebracht sind und mindestens 1 Meter Abstand zu Wänden und der Schallquelle haben. Dieses Vorgehen minimiert frühe Reflexionen, stehende Wellen und lokale Pegelabweichungen - Faktoren, die die Messgenauigkeit maßgeblich beeinträchtigen (Oltheten, 2019). Leider ist diese ideale Positionierung in unserem Fall praktisch nicht umsetzbar. So birgt Montage am Boden, Tischen oder gesonderte Ständererhöhte Gefahr von Beschädigungen, Verschiebungen und Manipulation. An der Decke jedoch befinden sich bereits vorhandene Löcher; diese können genutzt werden, um die Sensoren und den Mikrocontroller sicher zu befestigen. Auch den einen Meter Abstand zu Wänden und Schallquellen kann so eingehalten werden. Dieser Kompromiss ermöglicht eine schützende, wartungsarme und vergleichbare Positionierung der Sensoren. So bleibt der Messaufbau reproduzierbar, sicher und funktional, auch wenn die akustisch ideale Lösung nicht vollständig umsetzbar ist.

4.2 Deckenhalterung

Um die Hardware an der Decke zu befestigen, wurde eine spezielle Halterung entworfen, die eine sichere Montage ermöglicht. Diese Halterung nutzt die in den Decken vorhandenen "Löcher" für die Montage und wurde als eine Art Pin konzipiert.




Der in den Bildern Dargestellte Pin kann durch den Spalt in der Mitte in die Öffnung der Decke gesteckt werden. Durch die konische Form der Spitze des Pins wird garantiert, dass dieser auch bei der Demontage des Projekts keine Schäden hinterlässt. Das runde Loch, welches sich durch den Pin zieht, dient dazu, den Pin mit einer Schraube an der Hardware zu befestigen.


4.3 ESP32-Halterung

Der ESP benötigt eine Box, welche sicher an der Decke mit den Pins befestigt werden kann. Bei dem Design der Box wurde sich an einigen Vorlagen orientiert, um eine

optimale Passform zu gewährleisten. Die Box ist so gestaltet, dass sie den ESP32 sicher hält und gleichzeitig genug Platz für die Verkabelung bietet.




Die angesprochenen Löcher der Pins kommen in der Decke der Box zum Einsatz, um die Box sicher an der Decke zu befestigen. Diese werden durch die Löcher in der Decke mit Schrauben von innen befestigt.



4.4 Sensor-Halterung

Die Sensorhalterung wurde so entworfen dass sie platz für einen möglichen Dämpfer bietet, welcher um das Mikrofon befestigt werden kann. Auch diese Halterung wird mit den Pins an der Decke befestigt, jedoch wird sie nicht geschraubt sondern direkt mit den Pins gedrückt. Der Sensor wird dann einfach mit zwei schrauben an der Halterung befestigt.



5 Algorithmus zur Schallquellenlokalisierung

In diesem Kapitel werden verschiedene Ansätze zur Lokalisierung einer Schallquelle im Raum beschrieben. Die Verfahren unterscheiden sich in ihrer physikalischen Genauigkeit, im Rechenaufwand sowie in der praktischen Umsetzbarkeit. Es werden sowohl rein mathematische Interpolationsverfahren als auch modellbasierte und lernbasierte Methoden betrachtet.

5.1 Grundprinzipien

Ein präziser, aber aktuell nicht umsetzbarer Ansatz wäre die *Time Difference of Arrival* (TDOA) in Kombination mit Beamforming. Dabei wird die Zeitdifferenz der Schallausbreitung zwischen mehreren Mikrofonen gemessen. Über Verfahren wie Trilateration oder GCC-PHAT lassen sich daraus Einfallswinkel und Quelle berechnen. Da die vorhandene Hardware jedoch keine ausreichend genaue Zeitmessung erlaubt, konnte dieser Ansatz bislang nicht praktisch umgesetzt werden.

5.2 Betrachtete Verfahren

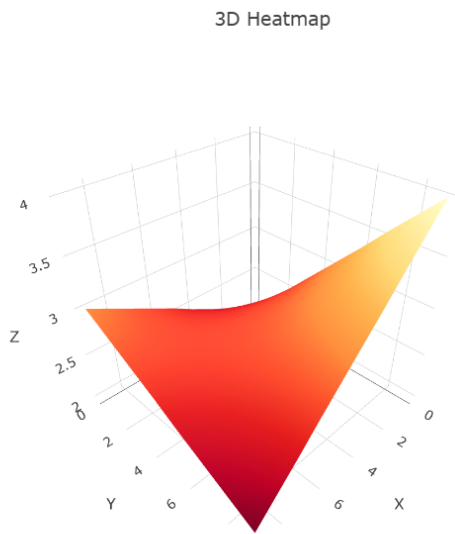
Bilineare Interpolation: Aus den vier Eckpunkten eines Messrasters wird durch zweifache lineare Interpolation eine flache Ebene gebildet. Dies liefert eine gleichmäßige, symmetrische Heatmap, berücksichtigt jedoch keinerlei physikalische Eigenschaften der Schallausbreitung. Damit eignet sich die Methode eher zur Visualisierung als zur tatsächlichen Lokalisierung.

```

1 for (let row = 0; row < 10; row++) {
2   const y = row / 9;
3   const rowData = [];
4   for (let col = 0; col < 10; col++) {
5     const x = col / 9;
6     const V =
7       sensorValues.d1 * (1 - x) * (1 - y) +
8       sensorValues.d2 * x * (1 - y) +
9       sensorValues.d3 * (1 - x) * y +
10      sensorValues.d4 * x * y;
11     rowData.push(Number(V.toFixed(2)));
12   }
13   grid.push(rowData);
14 }

```

Listing 5.1: Bilineare Interpolation




Inverse Distance Weighting (IDW): Hierbei wird der Einfluss eines Sensors umgekehrt proportional zur Distanz zur betrachteten Position gewichtet, häufig mit einem Distanzexponenten von $p = 2$ (inverse quadratische Gewichtung). Das Ergebnis ist eine weiche Heatmap, deren Maximum meist in der Nähe der lautesten Sensoren liegt. Bei mehreren Schallquellen oder komplexer Raumakustik verschwimmt jedoch das Ergebnis.

```

1 const power = 2; // Distanzexponent
2 for (let row = 0; row < 10; row++) {
3   const y = row / 9;
4   const rowData = [];
5   for (let col = 0; col < 10; col++) {
6     const x = col / 9;
7     let numerator = 0, denominator = 0;
8     for (const [key, { x: sx, y: sy }] of Object.entries(
9       sensorPositions)) {
10      const value = sensorValues[key];
11      const dx = x - sx;
12      const dy = y - sy;
13      const distance = Math.sqrt(dx * dx + dy * dy) || 0.0001;
14      const weight = 1 / Math.pow(distance, power);
15      numerator += value * weight;
16      denominator += weight;
17    }
18    rowData.push(Number((numerator / denominator).toFixed(2)));
19  }
20  grid.push(rowData);

```

Listing 5.2: Inverse Distance Weighting



Physikalisches Modell – Rückwärtsprojektion: Für jeden Punkt im Raum wird der erwartete Pegel an jedem Mikrofon berechnet:

$$L = L_0 - 20 \cdot \log_{10}(d)$$

mit d als Abstand zwischen Quelle und Mikrofon. Anschließend werden die berechneten Werte mit den real gemessenen Pegeln verglichen und die Abweichungen gespeichert. Eine Heatmap zeigt die Positionen mit den geringsten Fehlern als wahrscheinlichste Quelle an.

Maximum Likelihood Estimation (MLE): Dieser statistische Ansatz modelliert die Wahrscheinlichkeit, dass eine Quelle an Position (x, y) die gemessenen Pegel s_i erzeugt:

$$P = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(s_i - (L_0 - 20 \log_{10} d_i))^2}{2\sigma^2}\right)$$


Der Punkt mit der höchsten Wahrscheinlichkeit wird als Quellenposition angenommen. Das Verfahren ist robust gegenüber Rauschen, erfordert jedoch ein präzises Modell für Messfehler.

Weighted Centroid Localization (WCL): Jeder Sensorwert wirkt wie eine „Gravitationskraft“, die die geschätzte Quelle in seine Richtung zieht. Durch Berechnung des gewichteten Mittelpunkts aller Sensoren lässt sich eine einzelne (x, y) -Position bestimmen, die den Schwerpunkt der Schallstärke darstellt. Gut geeignet, wenn ein dominanter Bereich im Raum deutlich lauter ist.

```
1 power = 2;
2 for (const [key, { x, y }] of Object.entries(sensorPositions)) {
3   const value = sensorValues[key];
4   const weight = Math.pow(value, power);
5   weightedX += x * weight;
6   weightedY += y * weight;
7   weightSum += weight;
8 }
```

Listing 5.3: Weighted Centroid Localization (WCL)

3D Heatmap



Machine Learning: Durch Training eines Modells (z. B. KNN, Random Forest, MLP) mit bekannten Quellenpositionen und zugehörigen Pegelwerten kann die Quellenposition direkt aus den Messwerten vorhergesagt werden. Bei guter Trainingsbasis liefert dies sehr schnelle und präzise Ergebnisse. Allerdings sind umfangreiche und repräsentative Trainingsdaten erforderlich.

Kombinierter IDW-WCL-Ansatz: Zur Verbesserung der Lokalisierungsgenauigkeit wird zunächst eine IDW-Heatmap berechnet. Anschließend wird der durch WCL ermittelte Schwerpunkt durch einen zusätzlichen Peak (z. B. Gauß-Blob) verstärkt und in die Heatmap eingeblendet. Dadurch lassen sich weiche Verteilungen mit einem klaren Maximum kombinieren.

```

1  for (let row = 0; row < gridSize; row++) {
2      const y = row / (gridSize - 1);
3      const rowData = [];
4
5      for (let col = 0; col < gridSize; col++) {
6          const x = col / (gridSize - 1);
7          let numerator = 0;
8          let denominator = 0;
9
10         for (const point of interpolationPoints) {
11             const dx = x - point.x;
12             const dy = y - point.y;
13             const distance = Math.sqrt(dx * dx + dy * dy) || epsilon;


```

```

14     const weight = 1 / Math.pow(distance, idwFlatteningPower);
15     numerator += point.value * weight;
16     denominator += weight;
17 }
18
19 const interpolatedValue = numerator / denominator;
20 rowData.push(Number(interpolatedValue.toFixed(2)));
21 }
22
23 grid.push(rowData);
24 }

```

Listing 5.4: Kombiniertes IDW-WCL-Ansatz



5.3 Vergleich der Verfahren

Methode	Typ	Vorteile	Nachteile	Quelle bestimmbar?
Bilineare Interpolation	Interpolation	Schnell, symmetrische Heatmap	Kein physikalischer Bezug	Ungefähr
IDW	Interpolation	Einfach, intuitiv, glatte Heatmap	Kein klares Maximum	Ungefähr
Physikalisches Modell	Modellbasiert	Realitätsnah	Rechenintensiv, Annahmen nötig	Ja (Heatmap)
MLE	Wahrscheinlichkeit	Robust, statistisch fundiert	Modell für Fehler nötig	Ja (Wahrscheinlichkeit)
WCL	Schätzwert	Einfach, schneller Indikator	Ungenau bei asymmetrischen Verteilungen	Ja (Koordinate)
Machine Learning	Lernbasiert	Sehr schnell nach Training	Trainingsdaten nötig	Ja (xy direkt)

5.4 Fazit

Aus den Tests ergeben sich folgende Tendenzen:

- **Machine Learning** liefert bei guter Umsetzung die besten Ergebnisse, ist jedoch mit hohem Initialaufwand verbunden.
- **WCL** eignet sich gut, um den ungefähren Lautstärkenschwerpunkt im Raum zu bestimmen.
- **IDW** ist hilfreich, um Unterschiede in der Schallverteilung („hinten lauter als vorne“) darzustellen.
- **MLE** bietet hohes Potenzial für präzise Ortung, ist jedoch rechenintensiv und komplex in der Parametrisierung.

Eine Kombination aus IDW und WCL hat sich als vielversprechend erwiesen, um eine aussagekräftige Heatmap mit einem klar erkennbaren Maximum zu erzeugen. Zudem ist diese Methode relativ einfach zu implementieren und benötigt keine aufwändige Kalibrierung. Die Heatmap wird mit aktuellen Daten getestet, somit kann der Algorithmus durch die Gewichtung von IDW und WCL angepasst werden.

6 API-Kommunikation

In diesem Kapitel wird die Kommunikation zwischen Frontend und Backend beschrieben, insbesondere die Übertragung von Heatmap-Daten. Es werden verschiedene Ansätze zur Datenübertragung und -kompression vorgestellt, um die Effizienz und Performance der Anwendung zu optimieren.

6.1 Datenmengen und Optimierungsansätze

6.1.1 Problemstellung

Wenn für jede Slider-Position eine API-Abfrage durchgeführt wird:

- Bei einer Frequenz von 10 Hz (alle 100 ms ein Datenpaket) ergeben sich 36,000 Zeitpunkte pro Sensor und somit 144,000 Werte pro Stunde.
- Beispielrechnung: $36,000 \times 10 \times 10 = 3,6$ Millionen Werte für ein 10×10 -Array.

6.1.2 Datenbasis

- **Heatmap-Größe:** 10×10 Werte (100 Felder pro Heatmap)
- **Datentyp:** Float16 (2 Byte pro Wert)
- **Frequenz:** 10 Hz (alle 100 ms ein Frame)
- **Beispiel:** 1 Stunde = 3,600 Sekunden = 36,000 Frames

Speicherbedarf (unkomprimiert):

$$100 \cdot 2 \text{ Bytes} = 200 \text{ Bytes/Frame}$$

$$200 \cdot 36,000 = 7,200,000 \text{ Bytes} \approx 7.2 \text{ MB}$$

6.1.3 Optimierungsoptionen

1. Downsampling (Mittelwert pro Sekunde)

3,600 Frames/h $\rightarrow 3,600 \times 100$ Werte = 0.72 MB. Vorteil: geringe Datenmenge, einfaches JSON; Nachteil: Peaks nicht sichtbar.

2. Textkompression (Gzip/Brotli)

Reduktion auf ca. 15–25 % $\rightarrow \approx 1.8$ MB.

3. Binärformate (MessagePack, Protobuf, FlatBuffers)

30–40 % Ersparnis gegenüber JSON $\rightarrow \approx 5.0$ MB.

4. Binär + Kompression

Kombination aus beidem $\rightarrow \approx 1.2$ MB.

5. Delta-Encoding (nur Änderungen)

Angenommen: jeder 3. Wert ändert sich $\rightarrow \approx 3.4$ MB.

6. Delta-Encoding + Kompression

Weitere Reduktion auf ≈ 1.0 – 1.2 MB.

7. Pre-Exportierte Dateien

Backend exportiert pro Stunde eine Datei $\rightarrow \approx 7.2$ MB.

8. Pre-Export + Kompression

Speicherbedarf: ≈ 1.2 MB/h; sehr performant und cachebar.

6.1.4 Vergleich der Ansätze

Beschreibung	Speicher/h	Vorteile	Nachteile
Mittelwert pro Sekunde (Downsampling)	≈ 0.72 MB	Sehr leicht, JSON möglich, wenig Traffic	Daten stark geglättet, Peaks nicht sichtbar
JSON + Gzip/Brotli	≈ 1.8 MB	Einfach umsetzbar, keine großen Änderungen	Höhere Lesezeit, trotzdem noch Textformat
Binärformat	≈ 5.0 MB	Schnell zu dekodieren, weniger Overhead	Komplexere Integration im Frontend
Binär + Kompression	≈ 1.2 MB	Gute Mischung aus Effizienz & Geschwindigkeit	Backend-Implementierung aufwändiger
Delta-Encoding	≈ 3.5 MB	Ideal bei geringen Änderungen	Schlecht bei stark variablen Daten
Delta + Kompression	1.0–1.2 MB	Sehr gute Kompression	Schwer zu debuggen, komplex
Pre-Export (roh)	≈ 7.2 MB	Kein Runtime-Rechenaufwand, einfaches Caching	Hoher Speicherbedarf
Pre-Export + Kompression	≈ 1.2 MB	Sehr performant, cachebar, ideal für Slider	Dateiverwaltung nötig

Fazit

Aufgrund der hohen Komplexität und der großen Datenmengen ist es sinnvoll, die Heatmap-Arrays in einer separaten Datenbasis zu speichern. Das Frontend erhält die Daten in vorverarbeiteter Form durch Downsampling, um die Übertragungsmenge zu reduzieren und die Darstellungsgeschwindigkeit zu erhöhen. Zusätzlich wird eine Komprimierung der Daten in Betracht gezogen, um den Speicher- und Bandbreitenbedarf weiter zu minimieren, ohne die wesentliche Aussagekraft der Werte zu verlieren.

Literaturverzeichnis

Appventurez (2025), 'Node.js frameworks comparison: Express.js, koa.js, and more'.

Accessed: 2025-08-01.

URL: <https://www.appventurez.com/blog/node-js-framework>

Community, B. (2025), 'Koa.js vs express.js: Which node.js framework to choose?'.

Accessed: 2025-08-01.

URL: <https://betterstack.com/community/guides/scaling-nodejs/koa.js-vs-express.js>

Oltheten, W. (2019), 'The 7 steps of ideal mic placement'. Accessed: 2025-07-31.

URL: <https://sonicscoop.com/7-steps-for-ideal-mic-placement/>